

擾動單細胞 RNA 定序之拓撲資料分析的結構感知對照： 共變異數匹配虛無模型、繞行檢定，與一則警示案例

林 H.-T.¹ and 涂 Y.-H.¹

¹ 預印本——方法學報告。程式碼：<https://github.com/htlin222/sctda-cancer-plasticity>

June 12, 2026

Abstract

隨著拓撲資料分析 (TDA) 進入單細胞生物學，持續同調的純量摘要——最簡單者為最大一維持續性 ($\max-H_1$)——開始被讀作「環狀 (cyclic)」細胞狀態結構的量化指標，並被拿來跨條件比較。這有兩個各自已知、但在實務上未被同時控制的危險：在 Vietoris–Rips 濾流中，持續性的「大小」即使在純噪音下也會隨點雲的散佈（離散度）與取樣而增長 [3]；而細胞週期本身就是表達空間中的一個環 [1,5]。我們將四道對照整合成一套可重複使用的、適用於擾動 scRNA-seq 的顯著性程序——(i) 一個保留轉錄離散度的共變異數匹配高斯虛無模型；(ii) 一個在做任何環狀詮釋之前、先問該環是否被細胞「佔據」的圓形座標繞行檢定；(iii) 相對於離散度虛無模型而非以原始持續性來評估的細胞週期回歸；以及 (iv) 自助法方向性檢定——並在已知真值的合成資料上驗證（對真正被繞行的環敏感；對良性離散度與非高斯、非環狀結構具特异性）。作為警示案例，我們報告我們自己對五個縱向 EGFR 突變肺癌系統的分析：一個看似可信、可重現、跨尺度、與藥物相關的 $\max-H_1$ 訊號，在這些對照下瓦解——細胞從未繞行該環 ($R \geq 0.965$ ，相較於 12% 被佔據之對照的 0.881)、基線 $\max-H_1$ 等於離散度虛無模型、而體外的藥物超額其實是細胞週期環。該框架在真結構存在處亦能將其分離出來——PDX 殘存病灶中一個藥物誘發的多纖毛程式——顯示它同時能通過真訊號、也能拒絕被混淆的訊號。我們建議：隨著純量 TDA 讀數在單細胞生物學中日益普及，應將這些對照列為標準做法，並以開源程式碼釋出。

貢獻與既有工作的關係。 各個混淆因子與若干補救方法皆為已知；我們的貢獻在於將它們整合成一套適用於單細胞 H_1 的校正顯著性程序，附帶一個經驗證的操作點，外加一個誠實的失敗案例。

1. 一個適用於 scRNA-seq $\max-H_1$ 的共變異數匹配高斯虛無模型，用以控制離散度。主流已發表的 scTDA 虛無模型是「細胞內基因標籤洗牌」[1]，它會摧毀共變異數、因而幾乎被任何真實資料超越；TDA 理論面上更合理的替代是子取樣信賴集 [4]。一個保留離散度的虛無模型用於單細胞持續性，似乎尚未被使用過，儘管在嵌入幾何的「弱對照 vs 強對照」批判中已有先例 [9]。
2. 一個圓形座標繞行檢定 [10]，將「環被佔據」確立為任何「環狀」詮釋的前提。
3. 明確指出：以「原始 $\max-H_1$ 在 S/G2M 回歸後仍存在」為依據的細胞週期對照是不充分的，因為原始持續性被離散度主導 [3]；細胞週期的貢獻必須相對於離散度虛無模型來判斷。細胞週期成環的混淆本身已被確立 [1,5]；而原始持續性對照之不充分，據我們所知，尚未被指出。
4. 一個刻畫敏感度與特異度的合成基準，以及一個五系統的警示案例——我們自己的——其中一個被混淆的訊號可重現、跨尺度、卻是錯的，證明這個陷阱對謹慎的研究者而言是真實的。

1 引言

拓撲資料分析正進入單細胞生物學，已有綜述在彙整持續同調與 Mapper 應用於 scRNA-seq 的案例 [8]。其魅力在於能偵測軌跡推斷工具（為單向進程而設計）所無法量化的封閉、非樹狀結

構（環；一維同調 H_1 ）。隨著領域成熟，一個自然的步驟是以純量摘要拓撲—— $\max-H_1$ 、總持續性、持續性熵——並跨條件比較，將其上升讀作更多的環狀結構或可塑性。在癌症藥物耐受中這格外誘人：譜系追蹤顯示持續細胞會在多種狀態間可逆轉換，這種行為很容易被稱作「環狀」。

我們主張這一步需要當前實務未同時施加的對照，並提供之。兩個混淆因子各自皆有文獻記載。其一，Vietoris-Rips 持續性對點雲的散佈與取樣密度敏感：純隨機點的「最大持續環」會隨樣本數增長 [3]，原始持續性的尺寸與度量／尺度相關（因而催生了如持續性影像與持續性地景等穩定化摘要 [6,7]）且對離群值敏感（因而催生了密度穩健的濾流 [8b]）。擾動下轉錄離散度的上升因此可在真拓撲毫無改變時抬高 $\max-H_1$ 。其二，細胞週期在表達空間中描出一個圓 [5]，是 scRNA-seq 中 H_1 環的典型生成者；領域奠基的 scTDA 方法明言「細胞週期會在表達空間中產生週期性結構」[1]。常用的虛無模型並未控制前者（基因標籤洗牌 [1] 會摧毀包含離散度在內的共變異數），而一篇近期綜述指出單細胞 TDA 「可能不提供嚴謹的統計評估」、且對前處理敏感，卻未予解決 [8]。

這是一個預防性的貢獻，並非主張一個普遍的錯誤正在被犯：在 scRNA-seq 上做純量持續性對條件的比較仍不常見（既有的 scTDA 方法使用 Mapper 圖與逐細胞特徵 [1,2]），且已有控制樣本數並使用圖距離的謹慎應用 [11]。我們的重點是：當「純量讀數」這一步變得吸引人時，下述對照應隨之而來——而且這個陷阱是真實的，因為我們自己就掉了進去。我們以我們自己的五系統分析作為警示范例。

2 結果

對照框架

對每個條件，回報三個量加上一條決策規則。(1) 離散度檢定：觀測 $\max-H_1$ 與「對嵌入之均值與共變異數匹配的多元高斯」之 $\max-H_1$ 的比值；比值接近 1 表示該統計量可由離散度解釋，穩健地 > 1 則表示存在超越離散度的結構。(2) 繞行檢定：取自最具持續性之 H_1 類的圓形座標 [10] 之 Rayleigh 集中度 R ； R 接近 1 表示族群擠在單一角度（環未被佔據）。(3) 細胞週期檢定：在 S/G2M 分數回歸 [12] 後重算離散度比值。三者皆以自助法子取樣包裹 [4]；結論建立在「某個排序在多少比例的子取樣中成立」之上。決策規則：若高斯比值穩健地 > 1 則為超越離散度的結構；唯有同時 $R < 0.6$ 才是被繞行的環；若超額在 S/G2M 回歸後不存活則為細胞週期驅動。

框架在合成真值上兼具敏感度與特異度

在答案已知的點雲上（各 $n=1,200$ ，結構置於二維、嵌入 30 維並加上各向同性噪音；圖 4）：高斯團塊得到比值 0.93、 $R = 0.99$ （正確判為無結構）；均勻被繞行的環得到比值 8.35、 $R = 0.42$ （正確判為被繞行的環；敏感度）；稀疏非閉合弧得到比值 1.54、 $R = 0.96$ （有結構但未被繞行）；兩個分離的高斯團——非高斯但非環狀——得到比值 0.93（無結構；特異度）。高斯虛無模型不會對良性的非高斯性產生偽陽性，這正是對共變異數匹配虛無模型最關鍵的反對意見。第二個非參數、保留離散度的虛無模型（逐主成分置換）與之一致且更為保守。

案例研究：一個看似存在的藥物耐受拓撲訊號

我們在五個 EGFR 突變系統上計算 $\max-H_1$ （前 30 主成分， $\mathbb{F}_2$ ）。 $\max-H_1$ 在 osimertinib 細胞株與 PDX 模型中隨藥物上升（osimertinib D0→D14 為 1.41 → 3.78；PDX YU-006 未治療 → 殘存為 2.79 → 5.46；圖 1）。erlotinib 序列在此階段已是反例——訊號弱且非單調（D9 為 1.77、D11 為 1.08，是該序列最低）。

對照一——細胞並未繞行該環

圓形座標在每個世代中皆塌縮至單一角度：Rayleigh $R \geq 0.965$ （圖 2a）——比 12% 被佔據之陽性對照的 $R = 0.881$ 還要集中。譜系（Watermelon 條碼）若有不同，反而比隨機更集中。該環是一個族群並未佔據或繞行的稀疏特徵。

對照二——基線 $\max-H_1$ 即離散度

對共變異數匹配高斯虛無模型而言，基線 $\max-H_1$ 並未超越離散度（osimertinib D0/D3 比值 ≈ 0.9 ；觀測 $>$ 虛無模型者僅占 18–31% 的子取樣；圖 1）。超額僅在藥物下出現（osimertinib D7/D14 為 100%/98%；PDX 殘存為 99%）。由於高斯僅保留二階動差，其失效模式對「否定性結論」而言是保守的。

對照三——體外超額是細胞週期；體內超額不是

osimertinib D14 的超額由增殖細胞貢獻（差異表達：PTTG1、UBE2S、CKS1B、MYBL2；增殖標記 MKI67/PCNA/CCNB1/CDK1/ BIRC5，5/6），且在 S/G2M 回歸後不存活：D14 比值由 1.18 $\rightarrow$ 0.99，且 D14 $>$ D0 僅在 31% 的自助法中成立（圖 2b）。常見的對照——原始 $\max-H_1$ 在回歸後仍存在——會錯誤地下結論「不是細胞週期」，因為原始 $\max-H_1$ 被離散度主導 [3]。該框架是「分解」而非一律「拆穿」：在體內的 PDX 中，殘存超額並非細胞週期（去除增殖細胞後的 G1-only 比值為 2.07，90% CI [1.37, 2.61]，在 100% 的自助法中 > 1 ），但仍未通過繞行檢定（ $R = 0.965$ ）。橫跨全部五個系統：離散度解釋基線；細胞週期解釋體外超額；體內殘存則是真實但未被繞行——而在任何系統中， $\max-H_1$ 都未能佐證一個被細胞繞行的環。

一個抗混淆的譜系統計量在標準資料上力量不足

一個對抗譜系洗牌虛無模型的譜系狀態記憶統計量 $M(t) = 1 - H_{\text{obs}}/H_{\text{null}}$ 在 Watermelon 資料上並不穩健：基線的下降「被暗示」但不穩健（ $M(D0)$ 點估計 0.48，但 90% CI 為 $[-0.05, 0.29]$ ，且跨越零），而其在藥物下的衰減在不同分群設定下會變號（9 種設定中僅 3 種為正）、非單調，並在深度分層虛無模型下減半（圖 3）。原因是力量：每個時間點僅有 12–33 個含 ≥ 3 個細胞的克隆。

超越拒絕：框架能分離出一個真實、可詮釋的程式

一個對照框架唯有在「能通過真結構」時才值得信任（參見合成的真陽性）。PDX 殘存即為實例：其超額——唯一通過所有對照的訊號——由一個連貫的多纖毛氣道上皮程式驅動（PIFO、RSPH1、CFAP45/126/157、CAPS/CAPSL、CETN2、TPPP3；分泌性 AGR2/AGR3），在 YU-006 中為藥物誘發（未治療細胞中 0.1% $\rightarrow$ 殘存病灶中 9.6%；絕對數約 6 $\rightarrow$ 約 187 個細胞，同時腫瘤體積縮小三倍），與 EGFR-TKI 持續細胞已知會採取的分化譜系狀態一致。兩個界線：該程式具模型專一性（在 YU-003 中不存在），且在缺乏匹配正常參照的情況下，拷貝數推斷無法判定這些纖毛細胞是腫瘤來源（轉分化）還是被擴增的非惡性族群。此真實結構仍未通過繞行檢定。

3 方法

GEO GSE134839/150949/243562/131907 加 Maynard 2020；scanpy 之 QC / HVG / PCA（種子 42），子取樣至 1,000–1,500 個細胞；ripser 0.6 之 Vietoris-Rips 至 H_1 ，於前 30 主成分（ $\mathbb{F}_2$ ）。離散度虛無模型：自嵌入點雲的 $\mathcal{N}(\hat{\mu}, \hat{\Sigma})$ 抽樣，比值 = 觀測值 / 虛無模型中位數，30 次自助法子取樣加 90% 信賴區間，第二虛無模型為逐主成分置換。繞行檢定：dreimac 之 CircularCoords（DSPVJ [10]），Rayleigh R （驗證：噪音圓 $R = 0.12$ ；12% 被佔據之環 $R = 0.88$ ）。細胞週期檢定：留一群、Wilcoxon 差異表達、S/G2M 回歸 [12]，並以自助法重算離散度比值。體內身分：對原始計數做差異表達、跨 PDX 評分纖毛特徵、以 infercnvpy 做 CNV。程式碼：scripts/16_*.py–scripts/27_*.py（MIT）。

4 討論

一個跨系統的藥物耐受拓撲訊號——上升的 $\max-H_1$ ——大致由轉錄離散度、以及在體外由細胞週期所解釋；而在仍存有真正非混淆結構之處，它依然無法佐證環狀可塑性，因為族群並未繞行它。這個看似訊號者在五個系統中看來都很有說服力、通過了一個「已發表式」的細胞週期對照、並在病人腫瘤中「重現」——這正是這些對照之所以重要的原因：一個被混淆的統計量可以




Figure 1: 觀測 $\max-H_1$ 對共變異數匹配高斯（離散度）虛無模型，橫跨五個系統。百分比：觀測 > 虛無模型的自助法比例。超額僅在藥物下出現。

同時可重現、跨尺度、而且是錯的。我們的貢獻是預防性且整合性的。各混淆因子皆有先前文獻——持續性對密度／樣本數的依賴 [3]、細胞週期環 [1,5]、單細胞 TDA 的前處理敏感性與缺乏顯著性檢定 [8]，以及最接近我們論點者：在單細胞基礎模型嵌入中，於弱（洗牌）對照下顯著的幾何結構，在更強對照下會消失 [9]。我們在標的與虛無模型上不同（原始表達 H_1 加共變異數匹配高斯虛無模型，相對於嵌入幾何加重連線虛無模型），並貢獻了將離散度虛無模型、繞行檢定、與相對於離散度的細胞週期對照整合成單一、經真值驗證之程序。該框架亦浮現出殘存病灶中一個藥物誘發的多纖毛程式；其是否為賦予耐受性的腫瘤轉分化，是一個前瞻性、需實驗承載的研究計畫，而非重新分析。

展望。 要使此體內程式成為一項發現，需解決細胞來源（匹配正常之 CNV 或 EGFR 驅動基因定型）、在更多模型或病人殘存病灶檢體中重現，以及功能性測試該分化狀態是否賦予耐受。

限制。 細胞週期歸因僅在 osimertinib 細胞株上示範；PDX 殘存超額已證明非細胞週期，但其細胞來源未解。我們處理的是 $\max-H_1$ ；離散度虛無模型源自同一濾流，理應可推廣至其他持續性摘要 [6,7] 與更高維同調，惟此處未測。

References

- [1] Rizvi AH, Cámara PG, Kandror EK, et al. Single-cell topological RNA-seq analysis. *Nat Biotechnol* 2017;35:551–560.
- [2] Nicolau M, Levine AJ, Carlsson G. Topology based data analysis identifies a breast-cancer subgroup. *PNAS* 2011;108:7265–7270.
- [3] Bobrowski O, Kahle M, Skraba P. Maximally persistent cycles in random geometric complexes. *Ann Appl Probab* 2017;27:2032–2060.
- [4] Fasy BT, Lecci F, Rinaldo A, Wasserman L, et al. Confidence sets for persistence diagrams. *Ann Statist* 2014;42:2301–2339.
- [5] Schwabe D, Formichetti S, Junker JP, Falcke M, Rajewsky N. The transcriptome dynamics of single cells during the cell cycle. *Mol Syst Biol* 2020;16:e9946.
- [6] Adams H, Emerson T, Kirby M, et al. Persistence images. *JMLR* 2017;18:1–35.
- [7] Bubenik P. Statistical TDA using persistence landscapes. *JMLR* 2015;16:77–102.




Figure 2: (a) 繞行檢定：所有世代 $R \geq 0.965$ ，相較於 12% 被佔據之對照的 0.881。(b) 體外藥物超額在 S/G2M 回歸後消失。




Figure 3: 合成真值：框架兼具敏感度（通過被繞行的環）與特異度（拒絕高斯團塊與雙團非高斯案例）。

- [8] Hernández-Lemus E. Topological data analysis in single cell biology. *Front Immunol* 2025;16:1615278. (8b : Chazal F, et al. Robust topological inference / DTM filtrations. *JMLR* 2017;18:1–40.)
- [9] Kendiukhov I. What topological and geometric structure do biological foundation models learn? *arXiv* 2026;2602.22289.
- [10] de Silva V, Morozov D, Vejdemo-Johansson M. Persistent cohomology and circular coordinates. *Discrete Comput Geom* 2011;45:737–759.
- [11] Mukherjee S, Wethington D, Dey TK, Das J. Clinically relevant features in cytometry via persistent homology. *PLoS Comput Biol* 2022;18:e1009931.
- [12] Tirosh I, Izar B, Prakadan SM, et al. Dissecting metastatic melanoma by single-cell RNA-seq. *Science* 2016;352:189–196.




Figure 4: 譜系記憶衰減並不穩健：D0→D14 的變化在不同分群設定下變號。